RETO: “ Advertising Dataset”

Reto

> *Analicemos la relación entre la inversión en publicidad en televisión, periodico, radio y las ventas del producto mediante una regresión lineal múltiple*

TEAM # 11

Entusiastas de los datos

TEAM # 11

Entusiastas de los datos

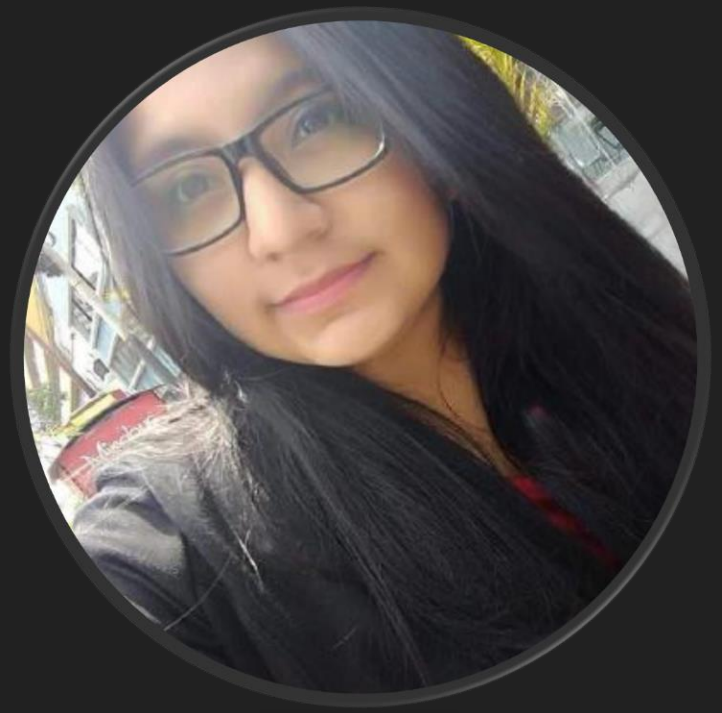

 # Becaria de DataSciencieFEM

Lic. en Computación Científica – UNMSM Perú

Interesada en el campo de Machine Learning.

DataSciencie en entrenamiento

Frase que me motiva:

"Nunca te rindas, lo que hoy es difícil, mañana será una conquista!"

Correo: Heydy.carrasco.huacca@gmail.com

LinkedIn: Heydy Mayumy Carrasco Huaccha|LinkedIn

GitHub: MayumyCH (github.com)

PASO 1: ENTENDIMIENTO DEL PROBLEMA

TEAM # 11

Entusiastas de los datos

PaRsel

🔎 Comprensión del Negocio

En este proyecto se propone el análisis de la data registrada en kaggle; buscamos promover las ventas de un determinado producto teniendo los siguientes datos: total de ventas de ese producto y gastos realizados en publicidad en los tres siguientes medios: TV, radio y periódico.

📌 Datos del proyecto

Este proyecto la data tiene 200 registros y 4 variables las cuales son las siguientes:

Variable	Variable Es	Definicion
TV	Televisión	Monto invertido en publicidad en TV
Radio	Radio	Monto invertido en publicidad en Radio
Newspaper	Periodico	Monto invertido en publicidad en Newspaper
Sales	Ventas	La cantidad de ventas que se logro

> Link del Repositorio del Proyecto

TEAM # 11

Entusiastas de los datos

PaRsel

PASO 2: IMPORTAMOS LAS LIBRERÍAS

FUENTE: BirDegree

```
[ ]  # Importacion de Librerias
     import pandas as pd # Manejo de data estructurada (Dataframe)
     import matplotlib.pyplot as plt # Graficas
     import seaborn as sns #Graficas mas sencillas
     import numpy as np #Manejo de matrices
```

> Link del Repositorio del Proyecto

PASO 3: CARGAR LA DATA Y ANALISIS DESCRIPTIVO

```
# Importar los datos desde el repositorio
url_data = "https://raw.githubusercontent.com/MayumyCH/datascience fem-datachallenge-monthly/main/advertising_multiple_linear_regression/data/advertising.csv"
dataset = pd.read_csv(url_data,sep = ",")
```

```
[ ] dataset.head()
```

	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	12.0
3	151.5	41.3	58.5	16.5
4	180.8	10.8	58.4	17.9

```
[ ] dataset.shape
    # INTERPRETACION:
    # 200 observaciones
    # 4 features/variables

    (200, 4)
```

```
dataset.info()
# Todos los features son numericos

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 4 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   TV         200 non-null    float64
 1   Radio      200 non-null    float64
 2   Newspaper  200 non-null    float64
 3   Sales      200 non-null    float64
dtypes: float64(4)
memory usage: 6.4 KB
```

```
[ ] # CANTIDAD DE NULOS POR CADA FEATURE
    dataset.isnull().sum()
    # No poseen variables nulas

    TV           0
    Radio        0
    Newspaper    0
    Sales        0
    dtype: int64
```

> Link del Repositorio del Proyecto

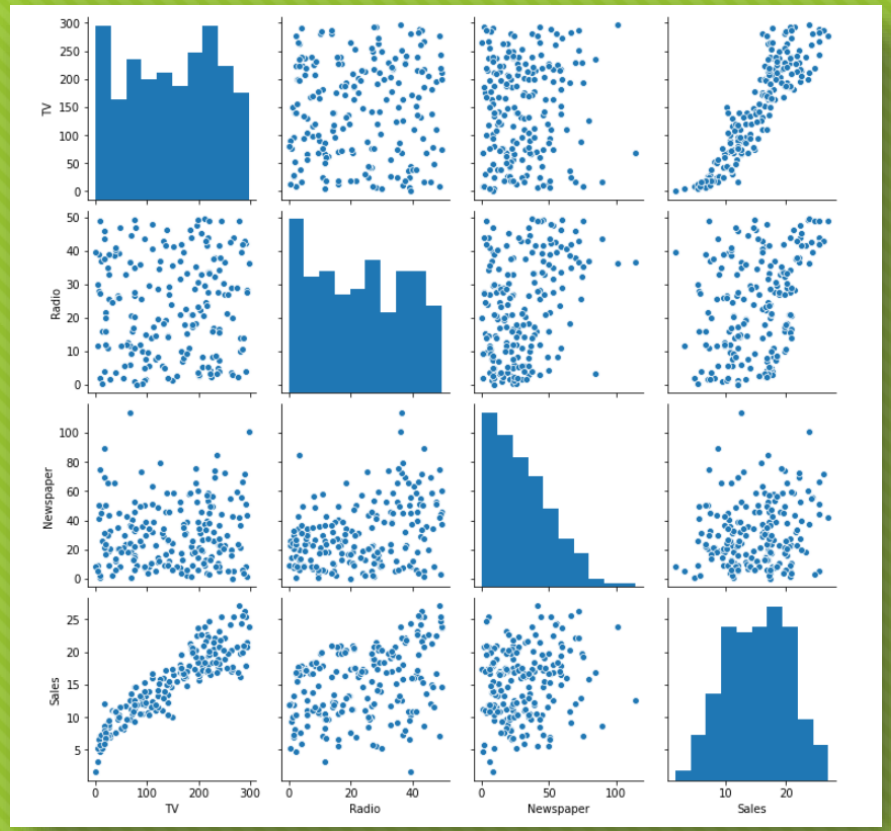

Diagrama de dispersión por pares usando Pairplots Seaborn

MATRIZ DE CORRELACIONES

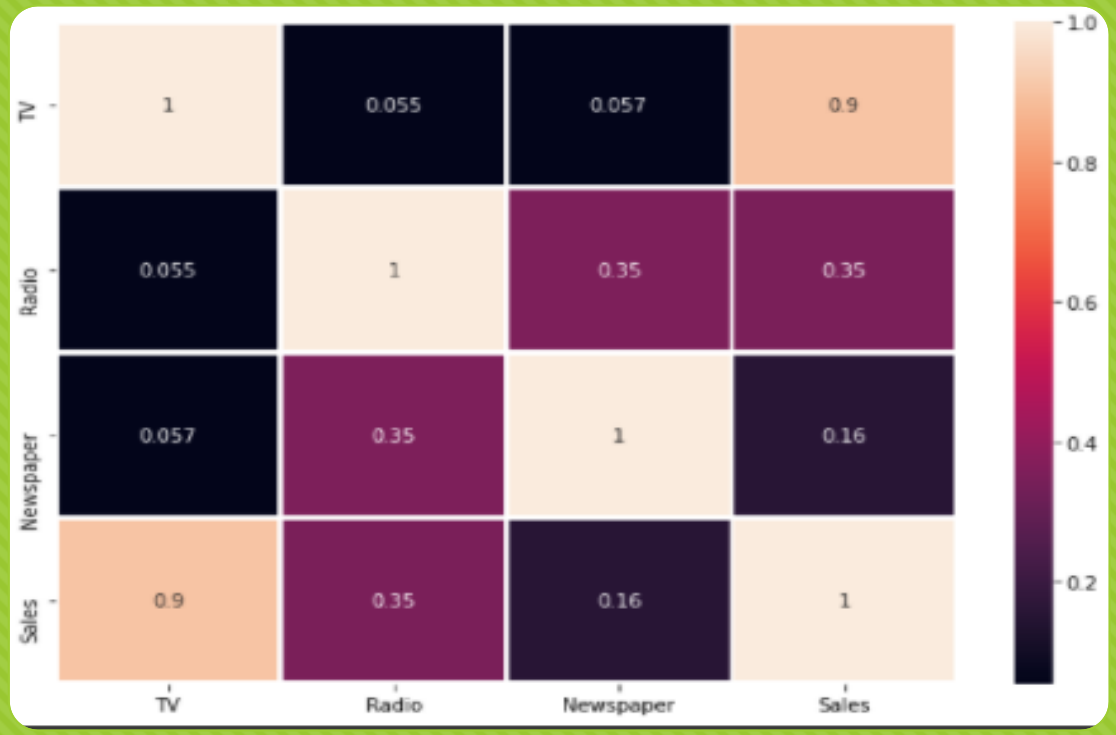

	TV	Radio	Newspaper	Sales
TV	1.000000	0.054809	0.056648	0.901208
Radio	0.054809	1.000000	0.354104	0.349631
Newspaper	0.056648	0.354104	1.000000	0.157960
Sales	0.901208	0.349631	0.157960	1.000000

PASO 4:

ANALIZANDO LAS CORRELACIÓN

```
dataset.corr()
# OBSERVACION
# Sales con TV tienen una alta correlación 0.90
# Sales con Radio tienen una correlación de 0.35
# Sales con Newspaper tienen una correlación 0.16

#NOTA: Cuando 2 variables tiene una correlacion > 0.6 ya es sign
ificativa (Mas cercano a 1 o -1)
```

REGRESIÓN LINEAL

La Regresión es un modelo que nos permite estimar la relación que existe entre una variable respuesta (y) y un conjunto de variables explicativas (x)

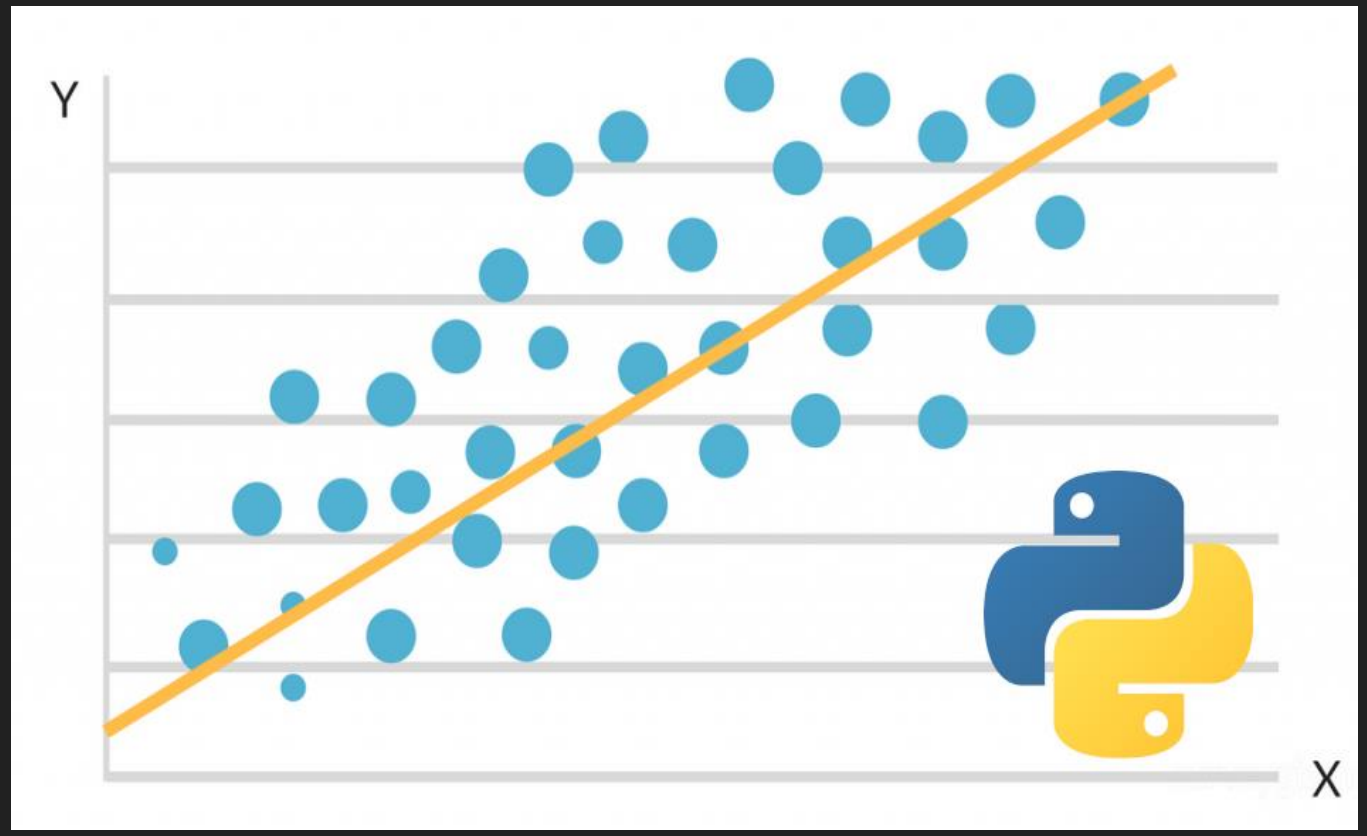

FUENTE: https://medium.com/@calaca89/entendiendo-la-regresi%C3%B3n-lineal-con-python-ed254c14c20

PASO 5:

MODELO

```
Index(['TV', 'Radio', 'Newspaper', 'Sales'], dtype='object')
```

Nuestra regresión multiple se veria de la sgte forma:

$$Y_{Sales} = a + b(X_{Tv}) + c(X_{newspaper}) + d(X_{Radio})$$

Más adelante se vera que una de las variables no nos proporciona tanto valor por ende no sera considerada

REGRESION MULTIPLE

```
# Definimos la variable respuesta y la variable predictora
target = 'Sales'
# predictoras = ['TV','Radio','Newspaper']
predictoras = ['TV','Radio']
# Solo se escoje las variables 'TV'y 'Radio' debido a que son
# las que explican mas la variabilidad de ventas
```

```
[ ] # Obtenemos del dataframe el conjunto de datos
    X = dataset[predictoras]
    y = dataset[target]
```

```
# Generamos el conjunto de train y test gracias a sklearn
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=123)
```

```
# Importamos el Modelo de Regresion Lineal
from sklearn.linear_model import LinearRegression
# Importamos las metricas de la regresion
from sklearn import metrics
# Creamos el modelo de la regresion
lm = LinearRegression() # Creando un objeto de Regresión Lineal 'lm'
```

```
# Entrenamiento del modelo
lm.fit(X_train, y_train)
```

```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None, normalize=False)
```

```
print("La intersección del modelo lineal:", lm.intercept_)
print("Los coeficientes del modelo lineal:", lm.coef_)
```

```
La intersección del modelo lineal: 4.483453135931349
Los coeficientes del modelo lineal: [0.05533174 0.10459835]
```


> Link del Repositorio del Proyecto

Nuestra regresión múltiple se vería de la siguiente forma:

YSales=4.48+0.06(XTv)+0.10(XRadio)

Interpretación:

Si no invertimos en publicidad en radio podremos decir que: Por cada aumento en una unidad de la inversión en publicidad en la Tv, el total de ventas del producto aumentará en 0.06 mil de dólares.
Si no invertimos en publicidad en tv podremos decir que: Por cada aumento en una unidad de la inversión en publicidad en la radio, el total de ventas del producto aumentará en 0.10 mil de dólares.
Cuando las variables predictoras sean 0, el total de ventas del producto es de 4.48 mil de dólares.

```
# Predecimos la data de entrenamiento y la data del test
train_pred=lm.predict(X_train)
test_pred=lm.predict(X_test)
```

```
# Visualizar el entrenamiento y la predicion
display(pd.concat([X_train, y_train], axis = 1).head()) # DATA REAL
train_pred[:5] # LA PREDICIÓN
```

	TV	Radio	Sales
81	239.8	4.1	17.3
107	90.4	0.3	12.0
112	175.7	15.4	17.1
145	140.3	1.9	10.3
8	8.6	2.1	4.8

```
array([18.18085714,  9.51682175, 15.81605411, 12.44523284,  5.17896262])
```

```
[ ] # R2 || Ajuste del modelo := Que porcentaje de la variación de y es esxplicado por x
print("Valor del R cuadrado del train:", round(metrics.r2_score(y_train,train_pred), 2))
print("Valor del R cuadrado del test:", round(metrics.r2_score(y_test,test_pred), 2))

# Se observa que nuestras variables predictoras explican en 91%
# Solo es 91% de la variación de Y (sales) es explicado por nuestras variables predictoras (x)
# Como se observa que el R2 del train y del test estan muy cerca significa que no hay overfiting
```

```
Valor del R cuadrado del train: 0.91
Valor del R cuadrado del test: 0.88
```

> Link del Repositorio del Proyecto

PASO 6: VALIDACIÓN DEL MODELO

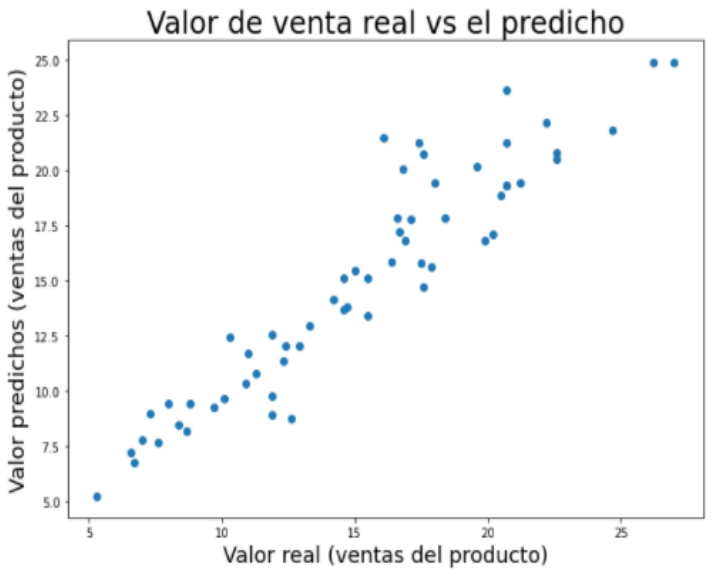


```python
# Calculando los errores
print("Calculando el Error Absoluto Medio (MAE)") # Que tan alejados estan mis valores reales de los predichos
print("MAE del Train:", metrics.mean_absolute_error(y_train,train_pred))
print("MAE del Test:", metrics.mean_absolute_error(y_test,test_pred))
print("\nCalculando el Error Cuadratico Medio (MSE)") # No se interpreta
print("MAE del Train:", metrics.mean_squared_error(y_train,train_pred))
print("MAE del Test:", metrics.mean_squared_error(y_test,test_pred))
print("\nCalculando la Raiz del Error Cuadratico Medio (RMSE)") # Raiz de MSE
print("MAE del Train:", np.sqrt( metrics.mean_squared_error(y_train,train_pred)))
print("MAE del Test:", np.sqrt(metrics.mean_squared_error(y_test,test_pred)))
# Que tan alejados estan mis valores reales de los predichos
# Mas penalizador
# Diferencia entre los valores reales y los valores predichos
```

```
Calculando el Error Absoluto Medio (MAE)
MAE del Train: 1.1933552055585421
MAE del Test: 1.3722057590910193

Calculando el Error Cuadratico Medio (MSE)
MAE del Train: 2.4886670192180094
MAE del Test: 3.2561838061058435

Calculando la Raiz del Error Absoluto Medio (RMSE)
MAE del Train: 1.5775509561399306
MAE del Test: 1.8044899019129599
```

> Link del Repositorio del Proyecto

> Link del Repositorio del Proyecto